

Explorando o uso de Vision Transformer na Classificação de Lesões Anais e Cervicais

Ingrid Bromerschenckel¹

¹ Departamento de Computação – Universidade Federal de Ouro Preto (UFOP)
Caixa Postal 35.400-000 – Ouro Preto – MG – Brazil

`ingrid.bromerschenckel@aluno.ufop.edu.br`

Abstract. *Although anal canal cancer (ACC) has a low incidence among gastrointestinal tract tumors, a significant increase in the number of cases has been observed, making it an emerging public health concern. This work introduces the topic and discusses potential approaches for ACC screening, based on a systematic review of the use of the Vision Transformer (ViT) architecture in the classification of cervical and anal cells, comparing its performance with other machine learning architectures. Cervical cells were included in the analysis due to their histological similarity to anal cells and the widespread clinical use of the Papanicolaou test. The objective of the review is to identify how ViT has been employed in the diagnosis of cervical cancer through conventional cytology and to investigate the feasibility of applying transfer learning techniques to the diagnosis of anal cancer. Based on the findings, models will be proposed using the "Cric Cervix" dataset—one of the most established in the literature for the study and classification of cervical lesions—with the aim of adapting these models for the identification of cellular lesions associated with ACC. The code will be available on GitHub, with access at: (<https://github.com/ingridbromer/reconhecimento-padroes>).*

Resumo. *Embora o câncer do canal anal (Anal Canal Cancer, ACC) apresente baixa incidência entre os tumores do trato digestivo, observa-se um aumento significativo no número de casos, configurando-se como uma questão emergente de saúde pública. Este trabalho propõe uma introdução ao tema e discute possíveis abordagens para a triagem do ACC, com base em uma revisão sistemática sobre o uso da arquitetura Vision Transformer (ViT) na classificação de células cervicais e anais, comparando seu desempenho com o de outras arquiteturas de aprendizado de máquina. As células cervicais foram incluídas na análise devido à sua semelhança histológica com as células anais e à ampla aplicação do exame de Papanicolaou na prática clínica. O objetivo da revisão é identificar como o ViT vem sendo empregado no diagnóstico do câncer cervical por meio da citologia convencional, além de investigar a viabilidade do uso de transferência de aprendizado para aplicação no diagnóstico do câncer anal. Com base nos achados, serão propostos modelos utilizando a base de dados "Cric Cervix", uma das mais consolidadas na literatura para o estudo e a classificação de lesões cervicais, com o intuito de estender esses modelos para a identificação de lesões celulares associadas ao ACC. O código está disponível*

no *GitHub*, com acesso em: (<https://github.com/ingridbromer/reconhecimento-padroes>).

1. Introdução

De acordo com a Organização Mundial da Saúde (OMS), cerca de 14,1 milhões de novos casos de câncer são diagnosticados anualmente em todo o mundo. O câncer é a segunda principal causa de morte global, sendo responsável por aproximadamente 9,6 milhões de óbitos por ano — e a tendência é que, nos próximos 25 anos, se torne a principal. O câncer de canal anal (*Anal Canal Cancer*, ACC) representa cerca de 4% das neoplasias malignas do trato digestivo inferior.

Embora o câncer anal apresente baixa incidência entre os tumores do trato digestivo, observa-se um aumento progressivo de casos, especialmente entre populações vulneráveis, como pessoas vivendo com o Vírus da Imunodeficiência Humana (HIV), imunossuprimidos, receptores de transplantes, indivíduos com histórico de neoplasias ou displasias cervicais e/ou vulvares de alto grau, além daqueles que praticam sexo anal receptivo com penetração — prática associada ao maior risco de microlesões na mucosa anal, facilitando a infecção por agentes como o Papilomavírus Humano (HPV) e o HIV. Nos Estados Unidos, a incidência de cânceres escamosos do ânus aumentou significativamente entre as décadas de 1970 e 2000, com destaque para homens, especialmente homens negros [Stewart et al. 2018].

A descoberta de que o HPV, particularmente os sorotipos 16 e 18, é a principal causa desse tipo de câncer, consolidou a compreensão do ACC como uma possível consequência de uma infecção sexualmente transmissível. Esse entendimento reforça seu potencial de prevenção por meio de estratégias de rastreamento baseadas em evidências, vacinação e diagnóstico precoce. Como há uma relação inversa entre o estágio da doença e a sobrevida, a detecção precoce surge como uma ferramenta essencial para reduzir a mortalidade e posiciona o câncer anal como uma preocupação relevante e tratável de saúde pública.

De forma semelhante, o câncer cervical é o quarto câncer mais comum entre mulheres no mundo, segundo dados da OMS [Bray et al. 2018]. A periodicidade do exame de Papanicolaou é um fator crucial na prevenção do câncer do colo do útero. A realização regular desse exame permite a detecção precoce de lesões precursoras, possibilitando intervenções eficazes antes que evoluam para formas invasivas da doença [Bernal et al. 2023].

Entretanto, o exame de Papanicolaou é altamente dependente da interpretação humana feita por citopatologistas, o que impõe desafios como falsos positivos e negativos, variações nos laudos e uma grande carga de trabalho físico e cognitivo [Gay et al. 1985, Bosch et al. 1992, Naryshkin 1997, Franco et al. 2006, Silva et al. 2017]. Essas dificuldades indicam a necessidade de novas abordagens que melhorem a precisão do diagnóstico e reduzam a sobrecarga dos profissionais de saúde.

Diante disso, surgem metodologias alternativas com potencial de auxiliar na análise das lâminas, como os sistemas de inteligência artificial e automação, que vêm mostrando resultados promissores ao reduzir erros humanos, aumentar a acurácia dos diagnósticos e otimizar o tempo de análise [Hou et al. 2022].

2. Trabalhos Relacionados

Uma revisão sistemática foi realizada em outubro de 2024 para entender sobre o emprego de ViT em lesões cervicais e anais. O modelo PICOC foi utilizado para estruturar as perguntas de pesquisa, considerando os seguintes elementos: População (pacientes com lesões e câncer do colo do útero e anal), Intervenção (aplicação ou extensão do ViT em modelos de classificação de imagens de citologia convencional), Comparação (modelos tradicionais ou de transferência de aprendizado entre tipos de câncer), Resultado (desempenho em termos de precisão diagnóstica e generalização), e Contexto (aplicações de Aprendizado Profundo para apoio a diagnósticos citopatológicos).

Com base nessa estrutura, foram formuladas duas perguntas de pesquisa principais: (1) Como o ViT tem sido empregado na classificação de lesões e câncer de colo do útero e anal em lâminas de citologia convencional? e (2) É possível estender o modelo de classificação de lesões cervicais para lesões anais?

A busca foi realizada em quatro acervos: (1) IEEE, (2) PubMed, (3) Scopus e (4) Web of Science (Figura 5). O critério de aceite incluiu artigos que estivessem dentro do escopo da proposta, ou seja, que abordassem sobre as células-alvo (cervicais e anais) e empregassem a citologia convencional como método de triagem.

Conforme a leitura dos artigos, os critérios de exclusão foram sendo delimitados em: (1) documentos duplicados; (2) literatura cinza - documentos que não passaram por canais formais de publicação científica, os quais, em geral, não são revisados por pares e apresentam menor rigor metodológico; (3) artigos cuja menção a ViT em células-alvo foi extremamente superficial, não sendo essas células empregadas no desenvolvimento do modelo; (4) artigos com ViT executado sobre imagens de outros órgãos (que não cólon, reto ou útero); (5) artigos com ViT executado sobre imagens obtidas por outros métodos (que não citologia convencional); (6) artigos com ViT empregado para outra finalidade que não a classificação de células.




Figura 1. Descrição da Revisão Bibliográfica

Ao todo, foram importados 277 artigos, sendo eles: IEEE – 62, Pubmed – 36, Scopus – 108, Web of Science – 71 (Figuras 6 e 7). Dos artigos identificados, 16 foram selecionados para leitura com base nos critérios de inclusão e exclusão estabelecidos.

Artigos por Fonte




Figura 2. Artigos selecionados por fonte

Número de artigos selecionados e aceitos por fonte




Figura 3. Artigos selecionados e aceitos por fonte

Os estudos selecionados foram publicados entre os anos de 2022 e 2024 (Figura 2.4).




Figura 4. Artigos aceitos por ano

2.1. Resultados e Discussão

Estudos recentes exploram diferentes variações do ViT e sua integração com CNNs para aprimorar a classificação de imagens cervicais e a detecção de câncer. As abordagens analisadas combinam as características locais extraídas pelas CNNs com a habilidade dos ViTs em modelar dependências globais, buscando aumentar tanto a precisão quanto a eficiência computacional.

As bases de dados utilizadas nos artigos analisados foram: SIPaKMeD, Herlev e CRIC, sendo as duas primeiras de imagens com células unicelulares, ou seja, o número de imagens é igual ao número de células (Tabela 1).

Tabela 1. Bases de Dados e Classificações Celulares

Base de Dados	Número de Imagens/Células	Classificações Celulares
SIPaKMeD	4.049/4.049	(a) Superficial-Intermediário, (b) Parabasal, (c) Koilocitótica, (d) Disqueratótica, (e) Metaplásica
Herlev	917/917	(a) Células Normais Superficiais, (b) Células Intermediárias Normais, (c) Células Parabasais Normais, (d) Lesão Intraepitelial de Baixo Grau (LSIL), (e) Lesão Intraepitelial de Alto Grau (HSIL), (f) Carcinoma In Situ, (g) Carcinoma Escamoso Invasivo
CRIC	400/11.534	(a) Células escamosas atípicas, não podem excluir uma lesão de alto grau (ASC-H); (b) células escamosas atípicas de significado indeterminado, possivelmente não neoplásicas (ASC-US); (c) lesão intraepitelial escamosa de alto grau (HSIL); (d) lesão intraepitelial escamosa de baixo grau (LSIL); (e) negativo para lesão intraepitelial ou malignidade (NILM); (f) carcinoma espinocelular (CEC)

As métricas de desempenho com destaque dos artigos (acima de 90%) foram divididas em duas tabelas, de acordo com as bases de dados empregadas - SIPaKMeD e Herlev ou CRIC (Tabelas 2 e 3).

Tabela 2. Resultados das Bases de Dados SIPaKMeD

Referência	Método	Base de Dados	Métricas de Desempenho
[Khowaja et al. 2023]	Cervix Visionator ELM	SIPaKMeD	Acur.: 98,89%, Prec.: 98,42%, Rec.: 97,87%, F1: 98,76%
[AlMohimeed et al. 2024]	ViT-PSO-SVM	SIPaKMeD	Acur.: 97,25%, Prec.: 97,25%, Rec.: 97,25%, F1: 97,23%
[Fang et al. 2024]	DIFF (CNN + ViT)	SIPaKMeD	Acur.: 96,02%, Prec.: 96,09%, Rec.: 96,04%, F1: 96,04%
[Liu et al. 2022]	CVM-Cervix	CRIC + SIPaKMeD	Acur.: 91,72%, Prec.: 91,80%, Rec.: 91,60%, F1: 91,70%
[Khowaja et al. 2024]	IATS	SIPaKMeD	Acur.: 95,88%, Prec.: 95,37%, Rec.: 96,25%, F1: 95,79%
[Hemalatha et al. 2023]	CervixFuzzyFusion (segm.)	SIPaKMeD	Acur.: 98,13%, Prec.: 97,4%, Rec.: 97,6%, F1: 97,6%
[Hemalatha et al. 2023]	CervixFuzzyFusion (não segm.)	SIPaKMeD	Acur.: 96,13%, Prec.: 90,2%, Rec.: 90,4%, F1: 90,2%
[Maurya et al. 2023]	VisionCervix CNN-LSTM	SIPaKMeD	Acur.: 95,80%, Prec.: 100%, Rec.: 95,80%, F1: 97,5%
[Maurya et al. 2023]	VisionCervix ViT-CNN	SIPaKMeD	Acur.: 97,65%, Prec.: 99,54%, Rec.: 97,65%, F1: 98,58%
[Pacal 2024]	MaxCerViXT	SIPaKMeD	Acur.: 99,02%, Prec.: 99,03%, Rec.: 99,04%, F1: 99,02%
[Emara et al. 2024]	HViT-Cerv	SIPaKMeD	Acur.: 98%, Prec.: 98%, Rec.: 98%, F1: 99%
[Sholik et al. 2024]	CNN+ViT PCA e LDA	SIPaKMeD	Acur.: 98,52%, Prec.: 98,81%, Rec.: 97,80%, F1: 98,28%

Nota: O método CervixFuzzyFusion empregou células "segm."(previamente segmentadas à classificação) ou "não segm."(não segmentadas), conforme indicado entre parênteses.

"Acur."é a abreviatura para Acurácia, "Prec." para Precisão, "Rev." para Revocação e "F1" para *F1-Score*.

Tabela 3. Resultados das Bases de Dados Herlev e CRIC

Referência	Método	Base de Dados	Métricas de Desempenho
[Abinaya and Sivakumar 2024]	3D CNN-ViT + KELM	Herlev	Acc. 98,6%, Prec. 97,5%, Rec. 98,2%, F1 98,4%
[AlMohimeed et al. 2024]	ViT-PSO-SVM	Herlev (Binário)	Acc. 97,78%, Prec. 97,94%, Rec. 97,77%, F1 97,80%
[Fang et al. 2024]	DIFF (CNN + ViT)	Herlev	Acc. 94,55%, Prec. 94,13%, Rec. 91,66%, F1 92,78%
[Li et al. 2024]	VTCNet	Herlev	Acc. 95,95%, Prec. 96,18%, Rec. 95,95%, F1 95,17%
[Sholik et al. 2024]	CNN+ViT (PCA/LDA)	Herlev	Acc. 97,83%, Prec. 98,75%, Rec. 92,86%, F1 95,52%
[Liu et al. 2022]	CVM-Cervix	CRIC + SIPaKMeD	Acc. 91,72%, Prec. 91,80%, Rec. 91,60%, F1 91,70%

Nota: O modelo ViT-PSO-SVM empregou classificação binária (Herlev - Binário) entre lesão ou não lesão nas imagens da base de dados, conforme indicado entre parênteses.

Alguns modelos se destacaram em relação às métricas de desempenho, indicando potencial para aplicação em diagnóstico de citologia convencional cervical.

Em relação a base de dados SipakMed, cabe destacar alguns artigos:

MaxCerVixT – Alcançou acurácia de 99,02%, precisão de 99,03%, revocação de 99,04% e *F1-score* de 99,02% na detecção de câncer cervical [Pacal 2024]. Esse modelo propôs uma versão otimizada e leve da arquitetura MaxViT, especificamente adaptada para imagens de citologia com resolução limitada. Entre as principais modificações estruturais foram a substituição dos blocos MBConv por blocos ConvNeXtv2, que oferecem maior eficiência na extração de características com menos parâmetros, e o uso de camadas MLP baseadas em *Global Response Normalization*, que melhoram a seletividade e a estabilidade do treinamento. O MaxCerVixT também incorporou atenção multi-eixo local e global por meio de mecanismos de janela e grade respectivamente, promovendo um aprendizado mais robusto de padrões morfológicos das células. Sua alta acurácia e rapidez na inferência destacam o modelo como uma alternativa eficaz e viável.

Cervix Visionator ELM – Com acurácia de 98,89% e precisão de 99,42%, o modelo atinge *F1-score* de 98,76% [Khowaja et al. 2023]. A proposta integrou a arquitetura convolucional EfficientNet-B0 e ViT. As características extraídas por ambas as redes foram combinadas e processadas por uma Máquina de Aprendizado Extremo, um classificador de camada única conhecido por sua alta capacidade de generalização e velocidade de treinamento. Essa combinação híbrida explora as forças complementares das arquiteturas CNN e ViT, resultando em uma abordagem eficiente, leve e altamente precisa.

HViT-Cerv – Este modelo híbrido, que combina CNN e ViT, obteve média de acurácia, precisão, revocação e *F1-score* em torno de 98% [Emara et al. 2024]. O artigo propôs três abordagens principais: modelos CNN tradicionais, uma arquitetura Vision Transformer (ViT-Cerv), e um modelo híbrido chamado HViT-Cerv. Este último obteve melhor desempenho, e foi avaliado utilizando as CNNs EfficientNetB0, DenseNet121, Xception e ResNet50, sendo que a fusão entre a EfficientNetB0 e o ViT obteve o melhor resultado (descrito acima).

CervixFuzzyFusion – O modelo obteve acurácia de 98,13% na classificação de células segmentadas e 96,13% em imagens não segmentadas, com altos valores de precisão e *F1-score* em ambos os casos [Hemalatha et al. 2023]. Sua arquitetura combina características locais extraídas por uma CNN (DenseNet201) e características globais obtidas por um modelo de ViT, com mecanismos de *Shifted Patch Tokenization* (SPT) e *Locality Self-Attention* (LSA). As características fundidas são refinadas por um processo de seleção baseado em lógica *fuzzy* (FFS, em inglês *Fuzzy Feature Selection*), que elimina atributos redundantes e melhora a eficiência do modelo. Essa abordagem híbrida se destaca por dispensar a necessidade de segmentação manual e por sua capacidade de generalizar bem mesmo em conjuntos de dados limitados.

Em relação as bases de dados Herlev e CRIC, cabe destaque aos artigos:

3D CNN-ViT com classificador KELM - Esse modelo combinou a capacidade de extração de características espaciais e temporais da 3D CNN com a habilidade do ViT de capturar representações visuais complexas. Sua arquitetura incluiu camadas de convolução 3D para extrair características das imagens cervicais e reduzir informações redundantes, seguida por módulos do ViT para extrair representações em diferentes níveis de abstração. Essas características foram então concatenadas por uma Rede de Pirâmide de Características 3D - uma CNN, aprimoradas por um bloco de exaltação 3D, outra CNN

e, finalmente, classificadas por uma Máquina de Aprendizado Extremo com *Kernel*. Os resultados demonstraram uma alta precisão de 98,6% [Abinaya and Sivakumar 2024].

ViT-PSO-SVM – Alcançando acurácia de 97,78% no conjunto Herlev e até 99,21% no conjunto SIPaKMeD, o modelo propôs uma abordagem híbrida que integrou o ViT para extração de características locais e globais, o algoritmo *Particle Swarm Optimization* (PSO) para seleção das características mais relevantes e redução de dimensionalidade, e um classificador *Support Vector Machine* (SVM) na etapa final de decisão [AlMohimeed et al. 2024]. Essa combinação permitiu ao modelo manter alta precisão, mesmo em cenários com dados limitados ou classes múltiplas, superando redes convolucionais e *Transfomers* isolados. Além disso, o uso de mapas de ativação (Grad-CAM) contribuiu para a interpretabilidade do modelo, na geração de mapas de calor que mostram as regiões da imagem que mais influenciaram a classificação.

CNN+ViT com PCA e LDA – Neste estudo, os autores avaliaram diversas combinações de arquiteturas para extração de características, utilizando modelos de CNNs (ResNet-50, DenseNet-121, VGG-16 e Inception-V3) para capturar informações locais e modelos de ViTs (ViT-B16, ViT-L16, ViT-B32 e ViT-L32) para capturar informações globais. Cada combinação foi testada individualmente, com as características extraídas sendo concatenadas e normalizadas. Para mitigar a alta dimensionalidade e eliminar redundâncias, aplicou-se uma etapa dupla de redução com Análise de Componentes Principais (ACP) seguida de Análise Discriminante Linear (ADL). As características reduzidas foram classificadas utilizando algoritmos tradicionais como SVM, K-NN, MLP e regressão logística. A melhor performance foi obtida com o uso da combinação CNN+ViT seguida por ACP, ADL e classificador SVM, atingindo acurácia de 97,83% e precisão de 98,75% no conjunto Herlev [Sholik et al. 2024]. No entanto, o artigo não especifica qual par de modelos (CNN e ViT) foi responsável por esse resultado, reportando os dados apenas de forma agregada. Ainda assim, os resultados evidenciam a eficácia da fusão entre características locais e globais para representar células cervicais em imagens de Papanicolau.

Os modelos citados acima demonstram alto potencial para o diagnóstico de citologia cervical, com ótimos resultados observados através das métricas de desempenho, e estratégias inovadoras de fusão e otimização de características.

Foram identificados dois estudos que empregaram ViT sobre a base de dados CRIC. O primeiro, CVM-Cervix, é um método híbrido para classificação de imagens de células cervicais usando uma combinação de CNN - para a extração de características locais, o ViT na captura de características globais, e um Perceptron Multicamadas para a classificação final. O método foi treinado em uma base de dados composta pela união dos datasets CRIC e SIPaKMeD, totalizando 8838 imagens divididas em 11 classes. As imagens foram aumentadas e normalizadas na etapa de pré-processamento. Na avaliação, o CVM-Cervix obteve uma acurácia de 91,72% no conjunto de teste, com precisão média de 91,80%, revocação de 91,60% e *F1-Score* de 91,70%, superando modelos tradicionais como DenseNet, ResNet e o ViT sem agregação a outro modelo [Liu et al. 2022].

Já o segundo artigo utilizou o modelo Deep Integrated Feature Fusion (abreviado nas Tabelas 2 e 3 como DIFF), que propõe uma arquitetura híbrida com dois ramos paralelos: um baseado em CNN para extração de características locais e outro baseado em ViT

para captura de informações globais. A integração entre essas duas representações é realizada por meio de blocos específicos de fusão, denominados DIFF blocks. Esses blocos combinam interativamente os mapas de características locais e globais por concatenação, convoluções 1×1 e 3×3 , e conexões residuais, promovendo uma fusão mais eficaz entre os dois tipos de informação. O método obteve um desempenho de destaque na base CRIC, com acurácia de 85,06%, precisão de 85,47%, revocação de 85,23% e *F1-Score* de 85,12% na tarefa de classificação multiclasse com seis categorias [Fang et al. 2024].

2.2. Conclusões

A integração entre CNN e ViT tem demonstrado, de maneira geral, um melhor desempenho na classificação de imagens médicas, especialmente em contextos com dados de baixa resolução ou estruturas complexas. Dos 16 artigos analisados, 11 utilizaram a combinação entre CNN e ViT — dez deles listados nas tabelas anteriores, sendo que um deles ([Shi et al. 2022])) empregou uma base de dados privada. Nessa abordagem, a CNN é responsável por extrair características locais detalhadas, como bordas e texturas, enquanto o ViT capta relações globais, contribuindo para uma detecção mais precisa, conforme demonstrado nos estudos.

Quatro artigos utilizaram ViT isoladamente, ou com outras abordagens que não envolveram CNNs ([Ding et al. 2024, Pacal 2024, AlMohimeed et al. 2024, Stegmüller et al. 2024])). Um artigo consistiu em uma revisão sistemática sobre o tema [Alias et al. 2022]. Embora o ViT isolado seja eficaz na captura de relações globais, ele tende a apresentar desempenho inferior em tarefas que exijam alta resolução de detalhes locais, um aspecto crítico na citologia cervical. Além disso, técnicas de transferência de aprendizado em células sanguíneas e o uso de modelos pré-treinados foram aplicados para melhorar a precisão e reduzir o tempo de treinamento.

Adicionalmente, não foram identificados estudos que explorassem a transferência de aprendizado para adaptação do modelo a outros tipos celulares. A única abordagem observada envolveu a aplicação de um modelo treinado em células cervicais para a classificação de células sanguíneas [Fang et al. 2024, Liu et al. 2022].

Diante desses resultados, evidencia-se a necessidade de empregar métodos de classificação mais eficazes para a base de dados CRIC, baseados no protocolo internacional Bethesda, com o objetivo de desenvolver um modelo de triagem com melhores métricas, proporcionando maior robustez e segurança ao paciente e ao profissional citopatologista. Além disso, considerando a similaridade histológica entre os epitélios cervical e anal, vislumbra-se a possibilidade de aplicar estratégias de transferência de aprendizado, adaptando modelos treinados para a classificação de células cervicais à análise de células anais — uma área ainda carente de diretrizes padronizadas e de dados rotulados. Essa abordagem representa um avanço promissor na detecção precoce de lesões anais em populações de risco, contribuindo para a redução de desigualdades diagnósticas e o fortalecimento das estratégias de rastreamento em saúde pública.

3. Materiais e Métodos

3.1. Base de Dados

Os métodos propostos serão avaliados utilizando a base de dados **CRIC Cervix** (<https://database.cric.com.br>), acessada em 7 de maio de 2025. Essa

coleção contém 400 imagens de lâminas de esfregaço cervical convencional (exame de Papanicolau), adquiridas por microscopia de campo claro com objetiva de 40x e ocular de 10x. As imagens foram capturadas por uma câmera digital Zeiss AxioCam MRc acoplada a um microscópio Zeiss AxioImager Z2, utilizando o software Axio Vision Zeiss.

A base é composta por 11.534 células rotuladas, cada uma representada por caixas delimitadoras (*bounding boxes*) de $100\text{ pixels} \times 100\text{ pixels}$. Desse total, 6.779 células foram classificadas como NILM, 606 como ASC-US, 925 como ASC-H, 1.360 como LSIL, 1.703 como HSIL e 161 como SCC. As anotações e revisões foram realizadas por quatro citopatologistas, seguindo a nomenclatura do Sistema Bethesda para a classificação de lesões celulares.

Como destacado anteriormente, das 11.534 células rotuladas, 4.755 foram classificadas como positivas para lesão celular e 6.779 como negativas. As imagens encontram-se segmentadas, com cada célula devidamente demarcada e classificada. A partir dessas segmentações, as células foram extraídas como regiões de interesse de $70\text{ pixels} \times 70\text{ pixels}$, centradas nas coordenadas do núcleo. Como essa dimensão é experimental, novos testes serão realizados variando seu valor para otimizar a extração de características celulares. Para garantir a consistência no tamanho das amostras, 425 células que não atendiam aos critérios de recorte foram descartadas.

Com o objetivo de mitigar o desequilíbrio entre as classes, principalmente no que se refere à quantidade reduzida de amostras da classe positiva, foi aplicado um processo sistemático de aumento de dados (*data augmentation*). Tanto esse processo quanto a extração de atributos foram baseados nos melhores resultados obtidos pelo grupo na base de dados CRIC [Diniz et al. 2021a, Diniz et al. 2021b]. O aumento de dados foi restrito exclusivamente ao conjunto de treinamento, de forma a evitar qualquer viés nos resultados de validação e teste, assegurando que os modelos fossem avaliados apenas com imagens não vistas durante o treinamento.

A partir do conjunto original de imagens positivas, foram geradas novas amostras sintéticas por meio da aplicação de transformações geométricas e fotométricas que preservam a estrutura e o conteúdo semântico da célula, mas introduzem variações visuais relevantes para o aprendizado do modelo. As transformações utilizadas incluíram: rotações em ângulos fixos (90° , 180° e 270°), espelhamento horizontal e vertical (*flip*), aplicação de filtros de desfoque, como o desfoque Gaussiano e o filtro da mediana, além de ajustes de contraste e nitidez (com aplicação de fatores variados utilizando funções de equalização e realce) (Figura 5). Cada transformação foi aplicada de forma controlada, resultando em um número proporcional de novas amostras, de modo que a quantidade final de imagens de cada classe se aproximasse das demais.




Figura 5. Exemplificação do aumento de dados sobre a uma mesma célula positiva para lesão.

Ao aplicar as transformações diretamente nas imagens originais antes da extração dos atributos, foi possível garantir que as alterações visuais fossem refletidas nos vetores de características extraídos posteriormente, contribuindo para a robustez e a capacidade de generalização do modelo. Os conjuntos de validação e teste foram mantidos intactos, contendo apenas imagens originais, a fim de assegurar uma avaliação justa e realista do desempenho dos modelos treinados.

3.2. Extração de Atributos

Embora as CNNs sejam capazes de aprender representações espaciais e texturais diretamente das imagens, este trabalho adota uma abordagem alternativa ao integrar a extração manual de atributos no processo de classificação. A principal motivação decorre da análise dos artigos incluídos na revisão bibliográfica, os quais utilizaram predominantemente modelos *end-to-end*, nos quais toda a representação é aprendida automaticamente, sem qualquer intervenção explícita na seleção ou extração de características. Essa predominância de abordagens puramente profundas pode sugerir a possibilidade de que informações relevantes estejam sendo subutilizadas.

Um conjunto abrangente de atributos foi extraído das imagens para caracterizar as células sob diferentes aspectos morfológicos, texturais e estatísticos, a fim de capturar informações relevantes para a classificação (Tabela 4). Para viabilizar a extração de atributos texturais, todas as imagens foram convertidas para escala de cinza.

Tabela 4. Atributos extraídos da imagem celular e suas respectivas descrições

Atributo	Descrição	Biblioteca	Qtd
Área	Área da célula segmentada	skimage.measure	1
Perímetro	Perímetro da célula segmentada	skimage.measure	1
Excentricidade	Grau de excentricidade da célula	skimage.measure	1
Circularidade	Circularidade baseada em área e perímetro	skimage.measure / numpy	1
Alongamento	Razão entre os eixos maior e menor da elipse equivalente	skimage.measure	1
Média	Média dos níveis de intensidade dos pixels	numpy	1
Desvio padrão	Desvio padrão dos níveis de intensidade dos pixels	numpy	1
Assimetria	Assimetria da distribuição de intensidade	scipy.stats	1
Curtose	Curtose da distribuição de intensidade	scipy.stats	1
Entropia	Entropia baseada no logaritmo da intensidade dos pixels	numpy	1
Contraste	Contraste da matriz de coocorrência de níveis de cinza	skimage.feature	1
Correlação	Correlação da matriz de coocorrência de níveis de cinza	skimage.feature	1
Energia	Energia (uniformidade) da matriz de coocorrência de níveis de cinza	skimage.feature	1
Homogeneidade	Homogeneidade da matriz de coocorrência de níveis de cinza	skimage.feature	1
Histograma LBP	Frequência de padrões locais binários (LBP)	skimage.feature	10
Texturas de Haralick	Atributos de textura baseados em Haralick (média entre direções da matriz de coocorrência de níveis de cinza)	mahotas.features.haralick	13
Atributos TAS	Estatísticas da Análise de Textura (TAS)	mahotas.features.tas	6
Momentos de Zernike	Momentos invariante de forma de Zernike até grau 8	mahotas.features.zernike_moments	25
Descritores de Fourier	Média, desvio padrão, energia e entropia espectrais	numpy	4
Total			72

Inicialmente, foram obtidos os **descritores de forma**, incluindo área, perímetro, excentricidade, circularidade e alongamento (razão entre os eixos maior e menor da elipse ajustada). Esses atributos geométricos fornecem informações essenciais sobre o tamanho, a compactação e o grau de alongamento da célula, permitindo distinguir morfologias

associadas a diferentes condições biológicas.

É importante destacar que as métricas de descritores de forma são obtidas a partir da segmentação da imagem em tons de cinza, utilizando limiarização automática (método de *Otsu*). Após a segmentação, é selecionada apenas a maior região conectada na imagem binarizada — geralmente correspondente à principal estrutura celular presente no recorte. Dessa forma, as métricas calculadas refletem características morfológicas dessa estrutura, e não do recorte como um todo. Cabe destacar que, como a segmentação depende do contraste entre a célula e o fundo, a região extraída pode corresponder ao núcleo celular ou, em alguns casos, incluir também parte do citoplasma. Essa abordagem foi escolhida por sua simplicidade e eficiência computacional, embora apresente limitações em casos nos quais a célula não esteja claramente destacada em relação ao fundo.

Em seguida, foram extraídas as **propriedades estatísticas da intensidade dos pixels**, tais como média, desvio padrão, assimetria (ou *skewness*), curtose e entropia da imagem. Esses atributos refletem a distribuição da intensidade luminosa e permitem inferir variações de brilho e contraste que podem estar relacionadas a alterações bioquímicas ou estruturais no tecido celular.

A seguir, foram computados os atributos derivados da **matriz de coocorrência de níveis de cinza (GLCM)**, incluindo contraste, correlação, energia e homogeneidade. Esses descritores quantificam a textura da célula com base nas relações espaciais entre os níveis de cinza, possibilitando a detecção de padrões como uniformidade, rugosidade e repetitividade.

Complementando a análise textural, foram extraídos os **histogramas do Padrão Local Binário (LBP)**, que representam a frequência de microtexturas locais como bordas, cantos e manchas. O LBP é robusto a variações de iluminação e captura eficazmente a microestrutura da imagem.

Outros **atributos texturais adicionais** incluem os descritores de **Haralick**, obtidos a partir de diferentes direções da GLCM e sintetizados em uma média. Esses atributos oferecem uma descrição mais rica e multidimensional da textura, com foco em propriedades como variância, entropia e uniformidade.

Além disso, utilizou-se a técnica **TAS (Texture Attribute Statistics)**, baseada na resposta de filtros projetados para realçar características como bordas, linhas e pontos. As estatísticas extraídas dessas respostas ajudam a detectar padrões microestruturais relevantes para a classificação.

No campo dos descritores de forma invariantes à rotação, foram incorporados os **momentos de Zernike**, que fornecem uma representação ortogonal e robusta da forma celular. Ao considerar momentos até o grau 8, obtêm-se medidas capazes de capturar características globais e locais da morfologia celular.

Por fim, foram extraídos os **descritores de Fourier**, por meio da Transformada Rápida de Fourier (FFT, do inglês *Fast Fourier Transform*). Esses atributos representam a imagem no domínio da frequência, capturando estruturas periódicas e padrões globais que podem não ser evidentes no domínio espacial. Foram calculadas quatro estatísticas principais: média espectral, desvio padrão, energia e entropia. A média e o desvio padrão indicam a distribuição de frequências, enquanto a energia avalia a intensidade total das

componentes frequenciais e a entropia reflete a complexidade espectral da imagem.

Todos os atributos passaram por uma etapa de normalização usando o método Min-Max, reescalando seus valores para o intervalo entre 0 e 1. Essa normalização é crucial para que atributos com diferentes unidades e escalas contribuam de maneira equilibrada durante o treinamento dos modelos de aprendizado de máquina, evitando que características com valores naturalmente maiores dominem a aprendizagem.

Dessa forma, a combinação integrada dos atributos — incluindo área, perímetro, excentricidade, circularidade, alongamento, média, desvio padrão, assimetria, curtose, entropia, contraste, correlação, energia, homogeneidade, histogramas LBP, descritores de Haralick, atributos TAS, momentos de Zernike e descritores de Fourier — fornece uma descrição abrangente das células cervicais. Essa diversidade de informações morfológicas, texturais e estatísticas contribui significativamente para a capacidade do modelo em identificar e classificar corretamente diferentes padrões celulares presentes nas imagens analisadas.

3.3. Modelos

Foi proposto pelo grupo um método de *ensemble* (técnica de combinação de modelos) utilizando dez arquiteturas de CNNs para a classificação de células cervicais da base de dados CRIC Cervix, seguindo o Sistema Bethesda. O método apresenta uma acurácia de 95%, precisão, revocação e *F1-Score* de 85% para a classificação simultânea de seis classes. Embora o método represente o estado da arte entre os modelos que utilizam CNNs nesta base de dados, os resultados ainda podem ser otimizados [Diniz et al. 2021a].

Com base nos modelos de melhor desempenho analisados na revisão bibliográfica, os selecionados para execução na base CRIC são o MaxCerVixT [Pacal 2024], e o ViT combinado com a CNN EfficientNetB0 [Khowaja et al. 2023, Emara et al. 2024]. Além disso, será implementada a estratégia de *ensemble* mencionada anteriormente, na qual três CNNs são executadas simultaneamente e suas previsões são combinadas por meio de votação majoritária, sendo utilizado como critério de desempate o resultado do modelo com maior sensibilidade média. Essa abordagem será complementada com o uso de um modelo ViT no conjunto.

Os experimentos serão organizados em três etapas: treino, validação e teste. As células serão divididas randomicamente. O conjunto de treino é composto por 70% das células (3.300 positivas e 4.505 negativas), o qual sofrerá o aumento de dados, enquanto os conjuntos de validação e teste utilizam, respectivamente, 15% das amostras (709 positivas e 942 negativas para validação; 704 positivas e 949 negativas para teste).

A classificação das imagens citopatológicas será realizada de forma progressiva (Figura 6), buscando otimizar os parâmetros dos modelos. Inicialmente, será utilizada uma abordagem binária: negativo para lesão celular (NILM) e positivo para lesão (ASC-US, LSIL, ASC-H, HSIL, CEC). Em seguida, será adotada uma classificação em três classes: negativo (NILM), atipia indefinida ou limítrofe (ASC-US e ASC-H), e lesão confirmada (LSIL, HSIL e CEC). Embora LSIL represente uma lesão de baixo grau e ASC-H uma atipia de significado incerto, opta-se por agrupá-las dessa forma devido à maior suspeita de gravidade clínica atribuída ao ASC-H, que pode ocultar lesões de alto grau como HSIL, apesar de não ser um diagnóstico confirmado. Por fim, será empregada a classificação completa com as seis categorias do Sistema Bethesda.




Figura 6. Classificações progressivas segundo o Sistema Bethesda.

3.4. Arquitetura do Modelo EfficientNet-B0 e ViT

Como primeiro experimento, foi escolhido o modelo da CNN EfficientNet-B0 conjugada ao ViT, exemplificado na Figura 7.




Figura 7. Exemplificação do Modelo EfficientNet-B0 + ViT.

3.4.1. Imagem de Entrada

As imagens de entrada utilizadas possuem três canais (RGB) e dimensão 70×70 pixels.

3.4.2. Bloco Inicial

Antes de processar a imagem com as estruturas principais do modelo, ela passou por um **bloco inicial** composto por:

- **Camada Convolutacional:** Essa camada aplica filtros que varrem a imagem, detectando padrões locais como bordas, texturas ou pequenos detalhes. Cada filtro gera um *mapa de ativação*, que destaca certas características da imagem.
- **Batch Normalization:** Técnica usada para normalizar os dados dentro da rede, o que ajuda na estabilização e aceleração do treinamento, reduzindo o risco de os valores explodirem ou se tornarem muito pequenos.
- **Função de Ativação ReLU (Rectified Linear Unit):** Essa função introduz não linearidade ao modelo. A *ReLU* mantém apenas os valores positivos e anula os negativos, permitindo que a rede aprenda relações mais complexas entre os dados. Sua definição matemática é dada por:

$$ReLU(x) = \max(0, x)$$

A escolha da *ReLU* neste ponto da arquitetura se justifica por sua simplicidade computacional e por ser altamente eficaz em redes convolucionais, onde é desejável manter a propagação do gradiente estável e eficiente. Apesar de não ser suave como outras funções, sua robustez e baixo custo computacional a tornam ideal para as primeiras camadas da rede.

- **Dropout:** Mecanismo de regularização que desativa aleatoriamente algumas conexões durante o treinamento. Isso evita que o modelo dependa demais de certas partes da rede, ajudando a prevenir *overfitting* ("memorização" dos dados de treinamento, sem capacidade de generalização para dados novos).

Após essa etapa, a imagem segue para dois ramos paralelos: o ramo ***Vision Transformer*** e o ramo **Convolutacional EfficientNet-B0**.

3.4.3. Ramo *Vision Transformer* (ViT)

Esse ramo do modelo processa a imagem como uma sequência de pequenos blocos (*patches*), simulando a maneira como *Transformers* de texto tratam palavras. O processamento segue as etapas abaixo:

- **Divisão em Patches:** A imagem já processada pelo bloco inicial é dividida em 196 blocos não sobrepostos de tamanho 5×5 , formando uma malha 14×14 de *patches*. Cada *patch* contém 64 canais de ativação e é transformado em um vetor de características de 64 dimensões por meio de uma convolução.
- **Embedding Posicional:** Como *Transformers* não possuem estrutura de grade como as CNNs, é necessário adicionar informações sobre a posição de cada *patch*. Isso é feito somando um vetor aprendido chamado *embedding* posicional.
- **Camadas Transformer:** O modelo contém 4 blocos *Transformer*, cada um com duas subcamadas:
 - **Multi-Head Self-Attention (Autoatenção Multi-Cabeça):** Essa técnica (descrita em detalhes anteriormente na Seção 2.1.3) permite que o modelo avalie a importância de cada *patch* em relação aos demais. Cada "cabeça" da atenção aprende uma perspectiva diferente da imagem, e suas saídas são combinadas.

- **Feedforward (MLP)**: Após a etapa de atenção, cada vetor de características é processado por uma rede neural totalmente conectada chamada *MLP (Multi-Layer Perceptron)*. Essa estrutura é composta por duas camadas lineares (*fully connected*), separadas por uma função de ativação não linear chamada *GELU*.

A função *GELU (Gaussian Error Linear Unit)* é uma ativação suave que combina as vantagens da *ReLU* com o comportamento probabilístico de ativações gaussianas. Diferente da *ReLU*, que zera os valores negativos de forma abrupta, a *GELU* realiza uma transição gradual entre ativar e não ativar um neurônio.

Matematicamente, ela é definida como:

$$GELU(x) = x \cdot \Phi(x)$$

onde $\Phi(x)$ representa a função de distribuição acumulada da normal padrão (CDF da distribuição gaussiana), dada por:

$$\Phi(x) = \frac{1}{2} \left(1 + \operatorname{erf} \left(\frac{x}{\sqrt{2}} \right) \right)$$

A presença da função erro (*erf*) torna a ativação suave e probabilisticamente ponderada: quanto mais positivo o valor de entrada x , maior a chance de ele passar pela ativação.

Esse tipo de função costuma apresentar melhor desempenho em tarefas de atenção, como em modelos *Transformer*, por permitir que pequenas variações nos dados influenciem de maneira mais gradativa a ativação dos neurônios. Além disso, a função *GELU* é amplamente utilizada em arquiteturas *Transformer* modernas, como o ViT, sendo considerada a ativação padrão nesses modelos por sua capacidade de modelar melhor relações contínuas e gradativas entre os elementos da entrada.

Para evitar *overfitting*, também é aplicada a técnica de *dropout* entre as camadas, que consiste em desativar aleatoriamente conexões durante o treinamento.

- **Conexões Residuais (*Residual Connections*)**: Cada subcamada é somada à sua entrada original, facilitando o fluxo de informação pela rede e ajudando no aprendizado de camadas mais profundas.
- **Agregação dos *Patches***: Ao final do processo, calcula-se a média dos vetores de todos os *patches*, resultando em um único vetor representando toda a imagem no contexto do ViT.

3.4.4. Ramo Convolutacional: *EfficientNet-B0*

O segundo ramo da arquitetura é responsável por capturar padrões locais nas imagens, como bordas, formas e texturas, por meio de CNN. Para isso, utilizamos uma arquitetura chamada *EfficientNet-B0*, conhecida por oferecer um excelente equilíbrio entre precisão e eficiência computacional. Essa rede foi originalmente treinada com milhões de imagens

do conjunto *ImageNet*, permitindo reutilizar seu conhecimento prévio através de uma técnica chamada *transfer learning*.

A *EfficientNet* é composta por vários blocos convolucionais organizados em estágios. Cada bloco contém:

- **Camadas Convolucionais:** Essas camadas aplicam filtros (ou *kernels*) sobre a imagem, varrendo-a de forma local para detectar padrões visuais. Inicialmente, esses filtros capturam bordas e contornos; em camadas mais profundas, passam a detectar formas complexas, como estruturas celulares.
- **Batch Normalization:** Após cada convolução, os valores são normalizados para manter a média e o desvio padrão consistentes durante o treinamento. Isso acelera o aprendizado e evita instabilidades numéricas.
- **Função de Ativação Swish:** Ao contrário da tradicional *ReLU*, a *EfficientNet* usa uma função chamada *Swish*, definida como $f(x) = x \cdot \sigma(x)$, onde $\sigma(x)$ é a função sigmoide. Essa função é suave e ajuda a manter os gradientes estáveis durante o treinamento, facilitando o aprendizado de representações profundas.
- **Redução da Dimensão Espacial:** Durante o processamento da imagem, a *EfficientNet-B0* aplica uma técnica chamada *stride*, ou passo da convolução, nas camadas convolucionais para reduzir a altura e a largura dos mapas de ativação. Especificamente, ao usar um *stride* maior que 1 (por exemplo, 2), o filtro é deslocado de forma mais espaçada, diminuindo a resolução da saída. Além disso, em alguns blocos, é utilizada a operação de *pooling* — normalmente *average pooling* ou *max pooling* — que resume regiões da imagem em valores únicos. Essas estratégias combinadas ajudam a construir representações mais compactas e abstratas, ao mesmo tempo que reduzem o custo computacional.
- **Camadas de Depthwise Separable Convolution:** Um dos diferenciais da *EfficientNet* é o uso de convoluções separáveis, que reduzem drasticamente o número de parâmetros sem comprometer a capacidade de extração de características.

Ao final da rede, é aplicada uma operação chamada **Adaptive Average Pooling**, que resume toda a informação espacial em um único vetor de 1280 dimensões. Esse vetor é uma representação abstrata e compacta da imagem, contendo as principais informações extraídas pelas camadas convolucionais.

3.4.5. Fusão dos Ramos e Atributos

As saídas do *ViT* (64 dimensões) e da *EfficientNet* (1280 dimensões) são combinadas através de uma **concatenação**, formando um vetor de 1344 características.

Além disso, o modelo também recebe um vetor de atributos numéricos (como textura ou forma da célula), com 72 valores. Esse vetor é igualmente concatenado, formando um vetor final de entrada para o classificador com 1416 dimensões.

3.4.6. Classificador Final

Esse vetor combinado é processado por duas camadas totalmente conectadas (*fully connected*):

- A primeira camada atua como uma etapa de compressão, transformando o vetor de alta dimensão em uma representação mais compacta e informativa, reduzindo a dimensionalidade para 256 neurônios. Em seguida, aplica-se a função **ReLU**, escolhida aqui por sua eficiência e boa performance em camadas densas, permitindo uma ativação direta dos neurônios positivos enquanto zera os negativos, conforme a fórmula $ReLU(x) = \max(0, x)$. Essa camada também utiliza **dropout** com taxa de 0,5 para reduzir o risco de sobreajuste.
- A segunda camada gera a predição final, com o número de neurônios correspondendo à quantidade de classes do problema de classificação.

3.4.7. Resumo Geral

O modelo híbrido de CNN EfficientNetB0 e ViT foi projetado para capturar:

- Padrões locais por meio da *EfficientNet-B0*;
- Relações globais entre regiões da imagem com o *Vision Transformer*;
- Conhecimento explícito de atributos previamente calculados.

Essa combinação busca maximizar a capacidade do modelo de reconhecer padrões relevantes nas imagens celulares, produzindo uma classificação precisa mesmo em cenários com variações morfológicas sutis.

4. Resultados

Como resultado preliminar, avaliou-se o desempenho do modelo híbrido de EfficientNetB0 e ViT aplicado à classificação de imagens de células cervicais em três diferentes cenários: binário (duas classes), intermediário (três classes) e completo (seis classes).

Para uma análise mais completa dos resultados, as métricas foram avaliadas sob três perspectivas: macro, micro e ponderada:

- **Média Macro:** calcula o valor de cada métrica para cada classe individualmente e em seguida obtém a média aritmética. É adequada para avaliar o desempenho em cenários com múltiplas classes, mas desconsidera a distribuição das amostras (ou seja, trata todas as classes igualmente).
- **Média Micro:** considera todas as predições globalmente, somando verdadeiros positivos, falsos positivos e falsos negativos antes de calcular as métricas. É mais representativa do desempenho geral em cenários com forte desequilíbrio entre classes.
- **Média Ponderada:** pondera as métricas individuais de cada classe pela proporção de instâncias que ela representa. Assim, combina as vantagens da média macro com a consideração do desequilíbrio de classes.

A Tabela 5 apresenta os principais indicadores de desempenho obtidos nos testes.

Tabela 5. Indicadores de desempenho nos cenários de classificação com duas, três e seis classes.

Métrica (%)	Tipo	2 classes	3 classes	6 classes
Acurácia	-	93.35	86.69	84.07
F1-Score	macro	93.22	80.45	72.67
	micro	93.35	86.69	84.07
	ponderada	93.36	86.55	83.94
Precisão	macro	93.09	81.05	72.90
	micro	93.35	86.69	84.07
	ponderada	93.40	86.45	83.86
Revocação	macro	93.38	79.91	72.50
	micro	93.35	86.69	84.07
	ponderada	93.35	86.69	84.07

A inclusão dessas três abordagens nos permite avaliar o desempenho do modelo de forma mais robusta, especialmente no cenário de seis classes, no qual há desbalanceamento entre categorias (nesse caso, por exemplo, apenas 24 imagens da classe CEC contra 961 da classe NILM na fase de teste do modelo).

Além das métricas numéricas, uma ferramenta visual fundamental para análise do desempenho do modelo é a **matriz de confusão**. Esta é uma representação tabular que compara as classes reais com as classes previstas pelo modelo. Cada célula da matriz, nesse caso, indica a quantidade e o percentual de imagens celulares classificadas como uma determinada classe, permitindo identificar padrões de acerto e erro.

Essa visualização é especialmente útil em cenários com múltiplas classes ou com desequilíbrio entre categorias, pois torna possível observar diretamente onde ocorrem as confusões mais frequentes entre classes específicas. No contexto deste trabalho, a matriz de confusão auxilia na interpretação qualitativa do modelo, revelando, por exemplo, se há confusão sistemática entre classes de lesões semelhantes ou entre casos limítrofes e negativos.

A seguir, são apresentadas as matrizes de confusão para os três cenários avaliados: classificação binária, classificação intermediária com três classes, e classificação completa com seis classes. Todas as matrizes estão normalizadas por linha, ou seja, os valores representam a porcentagem de acertos e erros relativos ao total de instâncias reais de cada classe.




Figura 8. Matriz de confusão normalizada — cenário binário (2 classes).




Figura 9. Matriz de confusão normalizada — cenário intermediário (3 classes).

Matriz de Confusão - 6 classes (Teste)

Real	NILM (961)	891 92.7%	8 0.8%	34 3.5%	18 1.9%	8 0.8%	2 0.2%
	ASC-US (140)	15 10.7%	106 75.7%	4 2.9%	0 0.0%	14 10.0%	1 0.7%
	LSIL (204)	34 16.7%	10 4.9%	129 63.2%	24 11.8%	7 3.4%	0 0.0%
	ASC-H (92)	27 29.3%	6 6.5%	10 10.9%	46 50.0%	3 3.3%	0 0.0%
	HSIL (255)	6 2.4%	16 6.3%	6 2.4%	1 0.4%	221 86.7%	5 2.0%
	CEC (24)	1 4.2%	1 4.2%	2 8.3%	1 4.2%	3 12.5%	16 66.7%
		NILM	ASC-US	LSIL	ASC-H	HSIL	CEC
		Predito					

Figura 10. Matriz de confusão normalizada — cenário completo (6 classes).

5. Discussão

Apesar dos avanços obtidos com a arquitetura proposta, o modelo híbrido exposto acima ainda apresenta algumas limitações que devem ser consideradas para trabalhos futuros e melhorias no desempenho.

Os resultados indicaram que o modelo apresentou maior eficácia na tarefa de classificação binária de imagens de células cervicais, distinguindo com maior precisão entre células com e sem lesões. No cenário intermediário, envolvendo três classes, o desempenho do modelo ainda foi considerado satisfatório, embora a classe limítrofe (que inclui ASC-US e LSIL) tenha se mostrado mais desafiadora de diferenciar. Isso pode ser atribuído à sobreposição de características morfológicas compartilhadas com as demais classes. Ainda assim, a correta identificação dessa classe tem relevância clínica, uma vez que alterações limítrofes geralmente estão associadas a infecções transitórias pelo papilomavírus humano (HPV) e tendem a regredir espontaneamente, por ação do sistema imunológico, sem necessidade de intervenção cirúrgica — sendo indicado apenas o acompanhamento médico periódico ([Instituto Nacional de Câncer José Alencar Gomes da Silva (INCA) 2016, Solomon et al. 2002, Massad et al. 2013])). Assim, o desempenho do modelo nesse cenário oferece um apoio valioso à tomada de decisão do profissional citopatologista.

Já na tarefa mais desafiadora com seis classes, a performance do modelo foi reduzida. A maior complexidade e o desbalanceamento entre classes (especialmente para CEC e ASC-H) impactaram os resultados. Ainda assim, o modelo manteve desempenho considerável nas classes NILM e HSIL, o que demonstra sua capacidade de generalização

para padrões mais distintos.

Sob uma primeira perspectiva, a divisão da base de dados foi realizada utilizando a técnica de *Hold-Out*, na qual os dados são divididos uma única vez entre os conjuntos de treino, validação e teste. Essa abordagem pode ser sensível à aleatoriedade da divisão e não necessariamente representar bem a variabilidade presente na base. Alternativas como a validação cruzada (*K-Fold*) poderão fornecer estimativas mais robustas e generalizáveis do desempenho do modelo, principalmente em cenários com classes desbalanceadas, sendo esse o próximo ponto de ajuste a ser considerado.

No que se refere aos atributos manuais, foi utilizada apenas a técnica de normalização *Min-Max*, a qual é sensível à presença de *outliers*. Métodos alternativos, como a padronização (*Z-score*), a normalização robusta baseada em mediana e intervalo interquartil (*RobustScaler*), ou ainda técnicas de normalização por quantis, poderiam ser avaliadas como formas mais eficazes de pré-processamento.

Além disso, não foi realizada uma análise de relevância dos atributos manuais utilizados. Todos os atributos extraídos foram incluídos diretamente na camada de fusão, sem aplicação de métodos de seleção ou redução de dimensionalidade. Isso pode introduzir ruído e dificultar o aprendizado do classificador. Ferramentas como a Análise de Componentes Principais (*Principal Component Analysis* – PCA), Análise Discriminante Linear (*Linear Discriminant Analysis* – LDA), valores SHAP (*SHapley Additive exPlanations* – SHAP), regressão LASSO (*Least Absolute Shrinkage and Selection Operator*) ou florestas aleatórias (*Random Forests*) poderiam auxiliar na identificação dos atributos mais relevantes para o problema em questão.

O processo de treinamento utilizou um número fixo de épocas (até 1000), com estratégia de parada precoce baseada na acurácia de validação. Essa configuração pode ser subótima, uma vez que a acurácia pode não ser a métrica mais sensível para indicar *overfitting*. Além disso, os hiperparâmetros foram ajustados manualmente (Tabela 6), sem o uso de métodos sistemáticos de otimização. Vale destacar que a EfficientNet-B0, utilizada como ramo convolucional do modelo, é um modelo pré-treinado com arquitetura fixa, resultado de uma extensa busca automatizada por arquiteturas eficientes e balanceadas. Por isso, sua estrutura e parâmetros básicos são pré-definidos, o que limita a possibilidade de ajustes arquiteturais durante o treinamento. Técnicas como busca em grade (*grid search*), busca aleatória (*random search*) ou otimização Bayesiana (por exemplo, com o uso do *Optuna*) poderiam ser incorporadas para buscar melhores configurações dos hiperparâmetros do modelo global.

Tabela 6. Hiperparâmetros da Arquitetura Híbrida EfficientNet-B0 e ViT

Hiperparâmetro	Descrição	Valor Atual
Tamanho da imagem de entrada	Resolução espacial das imagens de entrada (largura x altura)	70×70
Número de canais na primeira convolução / Bloco Inicial CNN	Define a dimensionalidade das ativações iniciais na CNN e no ViT, influenciando a capacidade de representação	64
Taxa de <i>dropout</i> / Bloco Inicial CNN	<i>Dropout</i> aplicado logo após as convoluções iniciais e ReLU para regularização	0,1
Cabeças de atenção / ViT	Quantidade de cabeças no mecanismo de atenção multi-cabeça, permite capturar múltiplas relações espaciais	4
Número de camadas / ViT	Quantidade de blocos de atenção + MLP aplicados no ramo transformer	4
Fator de expansão / MLP do ViT	Ampliação da dimensão interna do MLP para permitir maior expressividade	4
Taxa de <i>dropout</i> / ViT	Proporção de neurônios (unidades de ativação) descartados aleatoriamente nas camadas de atenção e MLP para evitar <i>overfitting</i>	0,1
Tamanho do <i>patch</i> / ViT	Dimensão dos <i>patches</i> quadrados usados para dividir a imagem no ViT	5
Taxa de <i>dropout</i> / Classificador Final	<i>Dropout</i> aplicado antes da camada linear final para evitar <i>overfitting</i> na fusão dos vetores	0,5

Outro aspecto relevante diz respeito ao pré-processamento das imagens de entrada, que são utilizadas em formato RGB. Cada canal (vermelho, verde e azul) carrega diferentes intensidades de cor, o que pode introduzir variações significativas nas representações extraídas caso não seja realizado um processo de normalização apropriado. Essa falta de padronização pode confundir o modelo, sobretudo na etapa de aprendizado das representações visuais. Embora técnicas como normalização por estatísticas do conjunto de dados (média e desvio padrão por canal) sejam amplamente utilizadas em arquiteturas pré-treinadas, como a EfficientNet, sua adaptação ao domínio específico das imagens cervicais é uma etapa crítica. Considerar normalizações específicas, baseadas nas distribuições reais de intensidade da base de dados, pode aprimorar a estabilidade do treinamento e a generalização do modelo, minimizando o impacto de variações de iluminação durante a aquisição das imagens sob microscopia ou coloração das lâminas.

No que diz respeito à arquitetura em si, a fusão das informações extraídas pelo ViT, pela EfficientNetB0 e pelos atributos manuais foi realizada de forma tardia, por meio da concatenação direta dos vetores de características. Essa abordagem, embora funcional, limita a capacidade do modelo de explorar interações complexas entre os diferentes tipos de representação. Por exemplo, padrões aprendidos por uma rede convolucional podem estar relacionados com medidas morfológicas específicas, mas essa correlação não é explicitamente aprendida pela rede em uma fusão tardia. Futuros estudos podem explorar estratégias de fusão mais profundas, como mecanismos de atenção cruzada entre os ramos, modulação condicional ou blocos de interação não lineares, que permitam que

os diferentes tipos de representação influenciem uns aos outros durante o processo de aprendizado.

Por fim, a avaliação do modelo se restringiu a métricas globais como acurácia, *F1-score*, precisão e revocação. Não foram realizadas análises complementares sobre instâncias mal classificadas, sensibilidade a ruídos, nem foram consideradas curvas ROC (*Receiver Operating Characteristic*), área sob a curva de precisão-revocação (*Area Under the Precision-Recall Curve* – PR-AUC) ou outras medidas que avaliem a confiabilidade do modelo. Análises desse tipo são especialmente importantes em contextos clínicos, nos quais a confiança na predição pode ser tão relevante quanto a predição em si.

Essas limitações não invalidam os resultados obtidos, mas apontam caminhos relevantes para avanços metodológicos e aprimoramentos futuros no sistema proposto.

6. Conclusão

A classificação precisa de lesões celulares em imagens obtidas a partir do exame de Papanicolaou é imprescindível para um melhor prognóstico do paciente. Nesse sentido, o presente trabalho propôs uma abordagem inovadora para a classificação de lesões cervicais e, futuramente, anais, por meio do uso de modelos baseados na arquitetura ViT e suas variações híbridas com CNNs. A partir de uma revisão sistemática da literatura, observou-se que modelos que combinam características locais extraídas por CNNs com dependências globais aprendidas por ViT vêm apresentando resultados promissores, superando muitas vezes abordagens tradicionais.

Com base nesse panorama, foi implementada uma arquitetura híbrida utilizando ViT e EfficientNet-B0 sobre a base de dados CRIC Cervix. Essa base foi escolhida por sua fidelidade às práticas clínicas reais, por conter imagens multicelulares rotuladas segundo o Sistema Bethesda. Os resultados preliminares evidenciaram o potencial da abordagem proposta, ainda que existam melhorias a serem realizadas e desafios a serem superados, como o desequilíbrio entre classes celulares. Ainda assim, a estrutura desenvolvida se mostra promissora para aplicações futuras, especialmente com ajustes nos hiperparâmetros, na composição dos modelos que ainda serão avaliados e na introdução de estratégias mais avançadas de atenção e normalização.

Adicionalmente, este trabalho reforça a relevância de expandir o escopo da detecção automatizada para além das lesões cervicais, incluindo também a triagem de lesões anais, uma condição cuja incidência tem aumentado nos últimos anos, especialmente em populações de maior vulnerabilidade. O câncer anal, embora menos prevalente, apresenta desafios diagnósticos semelhantes ao câncer do colo do útero e pode se beneficiar das mesmas estratégias computacionais de apoio ao diagnóstico. A proposta de transferência de aprendizado entre essas duas bases representa, portanto, uma oportunidade concreta de reaproveitamento de conhecimento em contextos clínicos relacionados, com potencial impacto na ampliação do acesso ao diagnóstico precoce e na redução de desigualdades em saúde.

Referências

Abinaya, K. and Sivakumar, B. (2024). A deep learning-based approach for cervical cancer classification using 3d cnn and vision transformer. *Journal of Imaging Informatics in Medicine*, 37:280–296.

- Alias, N. A., Mustafa, W. A., Jamlos, M. A., Alquran, H., Hanafi, H. F., Ismail, S., and Rahman, K. S. A. (2022). Pap smear images classification using machine learning: A literature matrix. *Diagnostics (Basel)*, 12(12):2900.
- AlMohimeed, A., Shehata, M., and et. al. (2024). Vit-pso-svm: Cervical cancer prediction based on integrating vision transformer with particle swarm optimization and support vector machine. *Bioengineering*, 11(7):729.
- Bernal, M., Bonono, C.-R., El-Halabi, S., Martí, J., Mwaka, A. D., Vassilakos, P., Jeronimo, J., and Gülmezoglu, A. M. (2023). Who recommendations and good practice statements on screening for cervical cancer. *International Journal of Gynecology & Obstetrics*, 160(S1):5–17.
- Bosch, M., Rietveld-Scheffers, P., and Boon, M. (1992). Characteristics of false-negative smears tested in the normal screening situation. *Acta Cytologica*, 36:711.
- Bray, F., Ferlay, J., Soerjomataram, I., and et al. (2018). Global cancer statistics 2018: Globocan estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA: A Cancer Journal for Clinicians*, 68(6):394–424.
- Ding, Q., Dong, X., and et. al. (2024). Improved yolov5 object detection method for cervical fluid cell pathological image detection. In *2024 IEEE IJCNN Conference*, Yokohama, Japan.
- Diniz, D., Rezende, M., Campos, A. G., and Souza, M. J. (2021a). A deep learning ensemble method to assist cytopathologists in pap test image classification. *Journal of Imaging*, 7(7):111.
- Diniz, D. N., Rezende, M. T., Bianchi, A. G. C., Carneiro, C. M., Ushizima, D. M., de Medeiros, F. N. S., and Souza, M. J. F. (2021b). A hierarchical feature-based methodology to perform cervical cancer classification. *Applied Sciences*, 11(9):4091.
- Emara, H. M., El-Shafai, W., and et. al. (2024). Cervical cancer detection: A comprehensive evaluation of cnn models, vision transformer approaches, and fusion strategies. *IEEE Access*.
- Fang, M., Fu, M., Liao, B., and et. al. (2024). Deep integrated fusion of local and global features for cervical cell classification. *Computers in Biology and Medicine*, 171:108153.
- Franco, R., Amaral, R., Montemor, E., Montis, D., Morais, S., and Zeferino, L. (2006). Fatores associados a resultados falso-negativos de exames citopatológicos do colo uterino. *Revista Brasileira de Ginecologia e Obstetrícia*, 28:479–485.
- Gay, J., Donaldson, L., and Goellner, J. (1985). False-negative results in cervical cytologic studies. *Acta Cytologica*, 29:1043–1046.
- Hemalatha, K., Vetrivelvi, V., Dhandapani, M., and Gladys, A. A. (2023). Cervixfuzzy-fusion for cervical cancer cell image classification. *Biomedical Signal Processing and Control*, 85:104920.
- Hou, X., Shen, G., Zhou, L., Li, Y., Wang, T., and Ma, X. (2022). Artificial intelligence in cervical cancer screening and diagnosis. *Frontiers in Oncology*, 12:851367.

- Instituto Nacional de Câncer José Alencar Gomes da Silva (INCA) (2016). *Diretrizes brasileiras para o rastreamento do câncer do colo do útero*. INCA, Rio de Janeiro, 2 edition. Acesso em: 07 jul. 2025.
- Khowaja, A., Zou, B., and Kui, X. (2024). Enhancing cervical cancer diagnosis: Integrated attention-transformer system with weakly supervised learning. *Image and Vision Computing*, 149:105193.
- Khowaja, A., Zou, B., and Xiaoyan, K. (2023). Cervix visionator elm: A novel approach to early detection of cervical cancer.
- Li, M., Que, N., Zhang, J., Du, P., and Dai, Y. (2024). Vtcnet: A feature fusion dl model based on cnn and vit for the classification of cervical cells. *International Journal of Imaging Systems and Technology*, 34(5).
- Liu, W., Li, C., Xu, N., and et. al. (2022). Cvm-cervix: A hybrid cervical pap-smear image classification framework using cnn, visual transformer, and multilayer perceptron. *Pattern Recognition*, 130:108829.
- Massad, L. S., Einstein, M. H., Huh, W. K., Katki, H. A., Kinney, W. K., Schiffman, M., Solomon, D., Wentzensen, N., and Lawson, H. W. (2013). 2012 updated consensus guidelines for the management of abnormal cervical cancer screening tests and cancer precursors. *Journal of Lower Genital Tract Disease*, 17(5):S1–S27.
- Maurya, R., Pandey, N. N., and Dutta, M. K. (2023). Visioncervix: Papanicolaou cervical smears classification using novel cnn-vision ensemble approach. *Biomedical Signal Processing and Control*, 79(Part 2):104156.
- Naryshkin, S. (1997). The false-negative fraction for papanicolaou smears. *Archives of Pathology & Laboratory Medicine*, 121:270.
- Pacal, I. (2024). Maxcervixt: A novel lightweight vision transformer-based approach for precise cervical cancer detection. *Knowledge-Based Systems*, 289:111482.
- Shi, J., Wu, K., Zheng, Y., He, Y., Li, J., Jiang, Z., and Yu, L. (2022). Global-local attention network for weakly supervised cervical cytology roi analysis. In *2022 IEEE 19th International Symposium on Biomedical Imaging (ISBI)*, pages 1–4. IEEE.
- Sholik, M., Fatichah, C., and Amaliah, B. (2024). Deep feature extraction of pap smear images based on convolutional neural network and vision transformer for cervical cancer classification. In *2024 IEEE International Conference on Industry 4.0, Artificial Intelligence, and Communications Technology (IAICT)*, pages 290–296, Bali, Indonesia.
- Silva, G., Cristovam, P., and Vidotti, D. (2017). O impacto da fase pré-analítica na qualidade dos esfregaços cervicovaginais. *Revista Brasileira de Análises Clínicas*, 49:135–140.
- Solomon, D., Davey, D., Kurman, R., Moriarty, A., O'Connor, D., Prey, M., Raab, S., Sherman, M., Wilbur, D., Wright, T., and Young, N. (2002). The 2001 bethesda system: terminology for reporting results of cervical cytology. *JAMA*, 287(16):2114–2119.

- Stegmüller, T., Abbet, C., and et. al. (2024). Self-supervised learning-based cervical cytology for the triage of hpv-positive women in resource-limited settings and low-data regime. *Computers in Biology and Medicine*, 169:107809.
- Stewart, D. B., Gaertner, W. B., Glasgow, S. C., Herzig, D. O., Feingold, D., and Steele, S. R. (2018). The american society of colon and rectal surgeons clinical practice guidelines for anal squamous cell cancers (revised 2018). *Diseases of the Colon & Rectum*, 61(7):755–774. Prepared on behalf of the Clinical Practice Guidelines Committee of the American Society of Colon and Rectal Surgeons.